

Разработка системы оценки сходства изображений для визуального поиска

Работу выполнил:

Трофимов Михаил Алексеевич, ПМ22-1

Научный руководитель:

к.ф.-м.н., доцент,

Калажоков Заур Хамидбиевич

Актуальность:

Современные CBIR-решения (поиск изображения по визуальному содержанию) не подходят для исследовательских целей, таких как подсчет метрик поисковой выдачи или поиска ошибок в разметке

Цель работы:

Разработка локальной системы оценки сходства изображений для визуального поиска, обеспечивающей возможность загрузки собственных моделей и структурированных датасетов для удобного подсчета метрик качества ранжирования

Объект:

Процесс визуального поиска изображений в локальных коллекциях на основе их содержания

Предмет:

Разработка и оценка системы визуального поиска изображений с использованием пользовательских моделей извлечения признаков и автоматического расчёта метрик качества ранжирования

Задачи:

- Провести анализ архитектурных подходов и функциональных возможностей современных глобальных и локальных CBIR-систем;
- Изучить методы сравнения объектов в векторном пространстве, основные метрики ранжирования, архитектуры нейронных сетей для генерации векторных представлений;
- Разработать приложение для визуального поиска изображений, поддерживающее исследовательские сценарии;
- Обучить собственную CNN-модель, готовую для использования в системах визуального поиска;
- Провести ряд экспериментов с разработанной системой.

Глобальные:

- Яндекс Картинки
- Google Images
- Bing Images

Локальные:

- Immich
- PhotoPrism
- DigiKam

Общие итоги:

- Поиск похожих изображений в современных системах строится вокруг нейросетевых эмбеддингов, либо включает их на каком-либо этапе, исключением является DigiKam, опирающийся на низкоуровневые признаки;
- Google и Microsoft явно используют многоуровневые системы для поиска похожих изображений;
- Immich и PhotoPrism являются self-hosted решениями.

Параметры:

- Датасет в формате ImageFolder;
- Препроцессинг;
- Retrieval-модель;
- Reranking-модель и её режим;
- Метод сравнения эмбеддингов (косинусное сходство, скалярное произведение или евклидово расстояние).

Итоги:

- Метрики ранжирования для отдельного запроса (Precision@k, Recall@k, Precision@1, HitRate@k, Average Precision);
- Метрики ранжирования по всему датасету (средние Precision@k, Recall@k, Precision@1, HitRate@k, mAP).

$$\text{sim}(x, y) = \frac{x \bullet y}{\|x\| * \|y\|}$$

Косинусное сходство

$$x \bullet y = \sum_{i=1}^d x_i y_i$$

Скалярное
произведение

$$\text{dist}(x, y) = \sqrt{\sum_{i=1}^d (x_i - y_i)^2}$$

Евклидово расстояние

$$\|x - y\|^2 = 2 - 2(x \bullet y)$$

При $\|x\| = \|y\| = 1$

$$P@k(q) = (1 / k) * \sum_{i=1}^k rel_q(i)$$

$$R@k(q) = (1 / R_q) * \sum_{i=1}^k rel_q(i)$$

$$AP(q) = (1 / R_q) * \sum_{i=1}^N P@i(q) * rel_q(i)$$


q — запрос, k — глубина выдачи, R_q — общее число релевантных изображений

Рассмотренные семейства нейросетей:


- CNN (ResNet-18, ResNet-50, ResNet101);
- ViT (vit-base-patch16, vit-base-patch32);
- DINO (dino-vits16, dino-vitb16);
- DINOv2 (dinov2-small, dinov2-base);
- CLIP (clip-vit-base-patch16, clip-vit-base-patch32).

Своя модель - архитектура

Структура BasicBlock




Архитектура ResNet101




Гиперпараметры:

- 30 эпох, размер батчей 512, кроп датасета до 128x128;
- Функция потерь CrossEntropyLoss;
- Оптимизатор AdamW;
- Планировщик lr CosineAnnealingLR.

Accuracy



CrossEntropyLoss



Технический стек:

Python как язык реализации приложения.

Streamlit — разработка интерактивного веб-интерфейса;

pyngrok — запуск приложения из Google Colab;

PyTorch — загрузка моделей и расчёт эмбеддингов изображений;

torchvision / PIL — чтение и препроцессинг изображений;

transformers — подключение встроенных моделей ViT, DINO, DINOv2 и CLIP;

pandas — формирование таблиц с результатами экспериментов.

Среда запуска: Google Colab с поддержкой CPU/GPU.

Датасет из 4000 фото с близкими классами **cat-breeds**

Цель — проверка моделей на сохранение тонких
визуальных признаков



American Shorthair



Persian



Russian Blue



Tiger

Эксперимент 1

Модель	Размер эмбединга	Времени на весь датасет, сек	Изображений/сек	Секунд/ изображение
resnet10ti	256	21,2844	187,9306	0,005321
resnet18	512	22,7465	175,8510	0,005687
resnet50	2048	29,1257	137,3356	0,007281
vitb_patch16	768	64,3576	62,1527	0,016089
vitb_patch32	768	28,9560	138,1405	0,007239
dino_vits16	384	30,0866	132,9493	0,007522
dino_vitb16	768	65,5906	60,9844	0,016398
dinov2s	384	37,3467	107,1045	0,009337
dinov2b	768	91,0576	43,9283	0,022764
clipvb_patch16	512	66,2365	60,3897	0,016559
clipvb_patch32	512	30,4485	131,3695	0,007612

Скорость инференса различных моделей

Эксперимент 2

similarity	normalize	P@1	P@10	R@10	HitRate@10	mAP
cosine	True	0,75	0,710925	0,007116366	0,974	0,504316685
dot	True	0,75	0,710925	0,007116366	0,974	0,504316685
euclidean	True	0,75	0,710925	0,007116366	0,974	0,504316685
dot	False	0,5683	0,4396	0,0044004	0,99725	0,385396748
euclidean	False	0,7403	0,698	0,006986987	0,97625	0,465765642

При L2-нормализации результаты ранжирования
идентичны

Эксперимент 3

model_name	similarity	normalize	P@1	P@10	R@10	HitRate@10	mAP
DINOv2-B/14	euclidean	False	0,8263	0,8025	0,008033033	0,976	0,701464148
DINOv2-B/14	cosine	True	0,826	0,8031	0,008039039	0,976	0,699122123
DINOv2-B/14	dot	False	0,8205	0,801825	0,008026276	0,977	0,698374079
DINOv2-S/14	cosine	True	0,8175	0,78835	0,007891391	0,97575	0,658950764
DINOv2-S/14	euclidean	False	0,8173	0,78705	0,007878378	0,97675	0,658693024
DINOv2-S/14	dot	False	0,8125	0,788525	0,007893143	0,975	0,658048174
DINO ViT-B/16	euclidean	False	0,79875	0,769	0,0077	0,9745	0,585972267
...							
CLIP ViT-B/32	dot	False	0,65625	0,596275	0,006	0,985	0,370483226
ResNet10TI	cosine	True	0,589	0,52925	0,0053	0,96125	0,356684055
ResNet10TI	euclidean	False	0,57875	0,52365	0,0052	0,96425	0,352630391
ResNet10TI	dot	False	0,3575	0,367725	0,0037	0,9295	0,288526829

Качество ранжирования лучших моделей и ResNet10TI

- Разработана локальная система визуального поиска изображений, ориентированная на исследовательские задачи;
- С нуля обучена и интегрирована в систему в качестве пользовательского экстрактора компактная сверточная модель ResNet10TI;
- Проведены эксперименты с ResNet, ViT, DINO, DINOv2 и CLIP на сбалансированном fine-grained датасете;
- Лучшее качество на выбранном датасете показала модель DINOv2-B/14, а собственная модель ResNet10TI подтвердила работоспособность сценария с загрузкой произвольных весов;
- Система может использоваться для сравнения моделей и поиска потенциальных ошибок в разметке изображений.

- Расширение системы за счёт добавления FAISS или другого ANN-индекса для обеспечения масштабируемого поиска по большим наборам изображений;
- Добавление поддержки новых моделей в качестве экстракторов признаков;
- Поддержка reranking-оценки на всём датасете для более полной оценки качества найденных результатов;
- Сохранение истории экспериментов и результатов поиска для улучшения UX;
- Интеграция с векторными базами данных для хранения эмбеддингов, метаданных изображений и результатов поиска в более удобном и масштабируемом формате;
- Реализация загрузки отдельного изображения-запроса без необходимости включения его в структуру датасета.

Язык интерфейса

ru



Система оценки сходства изображений для визуального поиска

Загрузите zip-архив с изображениями и выберите retrieval-модель. Приложение определит структуру датасета, загрузит модель на доступное устройство, рассчитает глобальные эмбединги и позволит выполнить поиск похожих изображений. Для отдельного изображения можно дополнительно включить reranking по глобальным или патчевым признакам.

Устройство

cuda

Zip-архив датасета



Upload

200MB per file • ZIP

Загрузите zip-архив датасета. После распаковки приложение покажет структуру, классы и найденные изображения.

Ссылка на ролик:

https://drive.google.com/drive/folders/1id7kPfm_sumVXS5xd62e5odi8x6tcyTc?usp=share_link

Ссылка на репозиторий: <https://github.com/MachineTrof/cbir-image-similarity>

Спасибо за внимание!